



UNIVERSIDADE DE SÃO PAULO

Escola Politécnica

PSI3431 – Processamento Estatístico de Sinais

Identificação de Sistemas com o Algoritmo LMS

Planta conhecida – MSE e EMSE

Integrante 1: José Victor Lyra de Castro

NUSP: 14747340

Integrante 2: Caio de Paula Colnago

NUSP: 12608900

Integrante 3: Artur Mateo Freire de Jesus

NUSP: 14745525

Código do projeto:

github.com/Art-Mat/PES

São Paulo
2026

Sumário

1	Parte 1	2
1.1	Visão geral da solução	2
1.1.1	Organização geral dos arquivos	2
1.2	Algoritmo, recursão e parâmetros utilizados	2
1.2.1	Problema de identificação	3
1.2.2	Critério e recursão do LMS	3
1.2.3	Configuração da simulação	4
1.3	Curva do erro médio quadrático (MSE)	5
1.4	Curva do erro médio quadrático em excesso (EMSE)	6
1.5	Análise dos resultados e justificativa das escolhas	7
2	Parte 2	8
2.1	Visão geral da solução	8
2.1.1	Organização dos arquivos da segunda parte	8
2.2	Modelo matemático e procedimento de identificação	8
2.3	Determinação da ordem da planta	9
2.4	Curvas de aprendizado do MSE	10
2.4.1	Entrada branca	10
2.4.2	Entrada correlacionada	11
2.5	Vetor estimado da planta desconhecida	12
2.6	Conclusão	12

1. Parte 1

1.1. Visão geral da solução

O código implementa a identificação de um sistema por meio de um filtro adaptativo LMS (*Least Mean Squares*). A planta é conhecida e possui dez coeficientes. Para verificar estatisticamente a convergência do algoritmo, o experimento é repetido em 1000 realizações, sempre utilizando novas sequências pseudoaleatórias de entrada e de ruído.

Em cada realização, o algoritmo executa as seguintes etapas:

1. gera um sinal de entrada branco;
2. calcula a saída da planta conhecida;
3. adiciona ruído à saída da planta;
4. calcula a saída do filtro adaptativo;
5. determina o erro entre a saída desejada e a saída estimada;
6. atualiza os coeficientes do filtro por meio do algoritmo LMS;
7. armazena os erros necessários para estimar as curvas de MSE e EMSE.

1.1.1 Organização geral dos arquivos

A implementação foi dividida em cinco arquivos, de forma a separar os parâmetros da simulação, o processamento do algoritmo e a geração dos gráficos. A organização adotada é apresentada na Tabela 1.1.

Tabela 1.1: Organização dos arquivos utilizados na implementação.

Arquivo	Responsabilidade
<code>main.m</code>	Iniciar a execução geral do projeto.
<code>PartOneConsts.m</code>	Centralizar os parâmetros e as constantes utilizadas na simulação.
<code>knownPlant.m</code>	Executar o processo de identificação da planta conhecida por meio do algoritmo LMS.
<code>PlotMSECurve.m</code>	Calcular a média dos erros quadráticos e gerar a curva de aprendizado do MSE.
<code>PlotEMSECurve.m</code>	Calcular a média dos erros quadráticos em excesso e gerar a curva de EMSE.

Essa separação torna a implementação mais modular e facilita sua manutenção. Os parâmetros da simulação ficam concentrados em um único arquivo, enquanto o processamento do algoritmo e as rotinas de visualização são mantidos em funções independentes. Dessa forma, alterações nos parâmetros, no algoritmo ou na apresentação dos resultados podem ser realizadas sem modificar toda a estrutura do projeto.

1.2. Algoritmo, recursão e parâmetros utilizados

1.2.1 Problema de identificação

A planta considerada é um filtro FIR de dez coeficientes, representado pelo vetor verdadeiro

$$w^o = [-0.5247 \ -0.2060 \ 0.3324 \ -0.2631 \ 0.2358 \ 0.0304 \ 0.3525 \ -0.4812 \ -0.0485 \ -0.2964]^T. \quad (1.1)$$

Embora w^o seja conhecido na simulação, ele é tratado como desconhecido pelo filtro adaptativo. O objetivo do LMS é obter uma estimativa $\hat{w}(i)$ a partir apenas da entrada e da saída observada. Para cada instante i , define-se o vetor de entrada

$$u(i) = [u(i) \ u(i-1) \ \dots \ u(i-9)]^T. \quad (1.2)$$

O sinal $u(i)$ é branco, gaussiano, de média nula e variância unitária.

Essa escolha é adequada porque o sinal branco excita todas as direções do filtro e, por possuir matriz de autocorrelação proporcional à identidade, favorece uma convergência uniforme dos coeficientes.

A saída observada da planta é

$$d(i) = u^T(i)w^o + v(i), \quad (1.3)$$

em que $v(i)$ é um ruído branco de saída, independente da entrada, com média zero e variância $\sigma_v^2 = 0,001$. A saída do filtro adaptativo e o erro de estimação são, respectivamente,

$$y(i) = u^T(i)\hat{w}(i), \quad e(i) = d(i) - y(i). \quad (1.4)$$

1.2.2 Critério e recursão do LMS

O critério a ser minimizado é o erro médio quadrático

$$J(w) = E[e^2(i)]. \quad (1.5)$$

O LMS substitui o gradiente estatístico de $J(w)$ por uma estimativa instantânea. Com a convenção adotada no código, a atualização dos coeficientes é

$$\hat{w}(i+1) = \hat{w}(i) + \mu u(i)e(i). \quad (1.6)$$

Essa recursão desloca os coeficientes na direção que reduz o erro quadrático observado. A solução tende à solução de Wiener $w^* = R_u^{-1}r_{du}$, sem exigir o cálculo explícito das correlações.

1.2.3 Configuração da simulação

Os parâmetros utilizados estão resumidos na Tabela 1.2.

Tabela 1.2: Parâmetros empregados na identificação da planta conhecida.

Parâmetro	Valor	Finalidade
Número de coeficientes L	10	Dimensão da planta e do filtro adaptativo
Realizações independentes	1000	Aproximação das médias estatísticas
Iterações por realização	500	Observação do transitório e do regime permanente
Passo de adaptação μ	0,02	Compromisso entre velocidade e erro residual
Variância da entrada σ_u^2	1	Entrada branca de potência unitária
Variância do ruído σ_v^2	0,001	Piso de erro irreduzível da observação
Semente aleatória	0	Reprodutibilidade numérica
Inicialização	$\hat{w}(0) = 0$	Ausência de conhecimento prévio da planta

Para cada realização, o vetor de entrada e os coeficientes estimados são zerados. Em cada iteração, uma nova amostra gaussiana é inserida em $u(i)$, calcula-se $d(i)$, obtém-se o erro e aplica-se a recursão do LMS. As realizações usam sequências independentes de entrada e ruído.

O procedimento pode ser resumido em quatro passos:

1. gerar $d(i) = u^T(i)w^o + v(i)$;
2. calcular $y(i) = u^T(i)\hat{w}(i)$ e $e(i) = d(i) - y(i)$;
3. armazenar o erro quadrático e o erro em excesso;
4. atualizar $\hat{w}(i+1) = \hat{w}(i) + \mu u(i)e(i)$.

O MSE experimental é obtido pela média dos erros quadráticos nas $M = 1000$ realizações:

$$\widehat{\text{MSE}}(i) = \frac{1}{M} \sum_{m=1}^M e_m^2(i). \quad (1.7)$$

Já o erro em excesso desconsidera diretamente o ruído de saída:

$$e_{a,m}(i) = u_m^T(i)(w^o - \hat{w}_m(i)), \quad \widehat{\text{EMSE}}(i) = \frac{1}{M} \sum_{m=1}^M e_{a,m}^2(i). \quad (1.8)$$

Como $R_u = I$, o maior autovalor é $\lambda_{\max} = 1$. O valor $\mu = 0,02$ é pequeno em relação aos limites usuais de estabilidade, sendo adequado para obter convergência suave e baixo erro residual, ainda que exija algumas centenas de iterações.

1.3. Curva do erro médio quadrático (MSE)

O MSE inclui tanto o erro decorrente da diferença entre os coeficientes quanto o ruído presente na saída:

$$\text{MSE}(i) = E[e^2(i)] = E[e_a^2(i)] + \sigma_v^2 = \text{EMSE}(i) + J_{\min}, \quad (1.9)$$

em que $J_{\min} = \sigma_v^2$, pois o ruído é independente da entrada e não pode ser previsto pelo filtro.




Figura 1.1: Curva de aprendizado do MSE, calculada sobre 1000 realizações.

Observa-se um curto crescimento inicial, associado ao preenchimento progressivo da linha de atraso e ao transitório dos coeficientes inicialmente nulos. Depois desse período, o MSE diminui de forma aproximadamente monótona e alcança o regime permanente por volta de 300 iterações.

O patamar final situa-se próximo de $-29,5$ dB, ligeiramente acima do limite ideal de -30 dB. Esse limite decorre diretamente da variância do ruído:

$$10 \log_{10}(\sigma_v^2) = 10 \log_{10}(0,001) = -30 \text{ dB}. \quad (1.10)$$

A pequena diferença é esperada: com passo constante, o LMS não permanece exatamente no ponto ótimo, mas oscila em torno dele, produzindo um erro de desajuste adicional.

1.4. Curva do erro médio quadrático em excesso (EMSE)

O EMSE mede apenas a parcela de erro provocada pelo afastamento entre os coeficientes estimados e os coeficientes verdadeiros:

$$\text{EMSE}(i) = E \left[\left| u^T(i)(w^o - \hat{w}(i)) \right|^2 \right]. \quad (1.11)$$

Assim, diferentemente do MSE, o EMSE não contém diretamente a potência do ruído de saída.




Figura 1.2: Curva do erro médio quadrático em excesso, calculada sobre 1000 realizações.

A curva apresenta o mesmo transitório inicial observado no MSE, seguido de queda contínua até aproximadamente 300 iterações. O regime permanente ocorre em torno de $-39,5$ dB, evidenciando que a parcela de erro associada ao desajuste dos coeficientes tornou-se aproximadamente dez vezes menor que a potência do ruído.

O EMSE não converge exatamente a zero porque o passo μ permanece constante. Mesmo depois de atingir a vizinhança de w^o , cada nova realização instantânea de entrada e ruído continua perturbando a estimativa. Um passo menor reduziria esse patamar, mas aumentaria o tempo necessário para a convergência.

1.5. Análise dos resultados e justificativa das escolhas

Os resultados confirmam a identificação da planta. Após aproximadamente 300 iterações, MSE e EMSE entram em regime permanente, indicando que os coeficientes estimados passaram a oscilar em uma pequena vizinhança dos coeficientes verdadeiros. A média de 1000 realizações reduz a variabilidade das curvas e permite interpretar os resultados como aproximações das esperanças estatísticas.

Para entrada branca gaussiana de variância unitária, o desajuste aproximado do LMS é

$$\mathcal{M} \approx \frac{\mu L \sigma_u^2}{2} = 0,10. \quad (1.12)$$

Consequentemente, as previsões de regime permanente são

$$\text{EMSE}_\infty \approx \mathcal{M} J_{\min} = 0,10 \times 0,001 = 10^{-4} \quad \Rightarrow \quad -40 \text{ dB}, \quad (1.13)$$

$$\text{MSE}_\infty \approx J_{\min} + \text{EMSE}_\infty = 0,0011 \quad \Rightarrow \quad -29,59 \text{ dB}. \quad (1.14)$$

Tabela 1.3: Comparação entre previsões teóricas e resultados observados.

Grandeza	Previsão aproximada	Valor observado
Início do regime permanente	cerca de 300 iterações	cerca de 300 iterações
MSE em regime permanente	−29,59 dB	aproximadamente −29,5 dB
EMSE em regime permanente	−40 dB	aproximadamente −39,5 dB

A proximidade entre teoria e simulação valida a implementação. O passo $\mu = 0,02$ mostrou-se uma escolha coerente: forneceu convergência estável dentro das 500 iterações e desajuste de aproximadamente 10%. Um valor maior aceleraria inicialmente a adaptação, mas elevaria o EMSE de regime permanente e poderia comprometer a estabilidade. Um valor menor reduziria o erro residual, ao custo de uma convergência mais lenta.

Também foi adequada a utilização de entrada branca, pois $R_u = I$ reduz a dispersão entre os modos de convergência. Para entradas coloridas, a maior separação entre os autovalores da matriz de autocorrelação tenderia a tornar a convergência mais lenta e desigual.

2. Parte 2

2.1. Visão geral da solução

Nesta etapa, a resposta ao impulso da planta não é fornecida. A identificação deve ser realizada exclusivamente a partir dos sinais de entrada e saída contidos nos arquivos `whites.mat` e `correl.mat`. Cada conjunto contém 100 realizações do mesmo sistema, sendo que o primeiro utiliza entrada branca e o segundo utiliza entrada temporalmente correlacionada.

2.1.1 Organização dos arquivos da segunda parte

Os arquivos empregados na segunda parte são apresentados na Tabela 2.1.

Tabela 2.1: Organização dos arquivos utilizados na identificação da planta desconhecida.

Arquivo	Responsabilidade
<code>unkownPlant.m</code>	Carregar os dois conjuntos de dados, determinar a ordem e executar as duas identificações.
<code>getOrder.m</code>	Calcular a solução de Wiener para ordens candidatas e gerar a curva MSE versus ordem.
<code>getMSE.m</code>	Avaliar o erro médio quadrático de um vetor de coeficientes sobre todas as realizações.
<code>adaptiveFilter.m</code>	Executar a recursão LMS, armazenar os erros quadráticos e estimar os coeficientes da planta.
<code>PartTwoConsts.m</code>	Armazenar a ordem máxima pesquisada e os passos de adaptação.
<code>whites.mat</code>	Fornecer 100 realizações com entrada branca, cada uma com 15000 amostras.
<code>correl.mat</code>	Fornecer 100 realizações com entrada correlacionada, cada uma com 50000 amostras.

2.2. Modelo matemático e procedimento de identificação

Admite-se uma planta FIR causal de comprimento desconhecido L , ou ordem $M = L - 1$. Para uma ordem candidata, define-se o vetor regressor

$$u(i) = [u(i) \ u(i-1) \ \dots \ u(i-M)]^T. \quad (2.1)$$

A saída observada é modelada por

$$d(i) = u^T(i)w^o + v(i), \quad (2.2)$$

em que w^o é a resposta ao impulso desconhecida e $v(i)$ representa o ruído de medição. Para um vetor estimado $\hat{w}(i)$, a saída do modelo e o erro são

$$y(i) = u^T(i)\hat{w}(i), \quad e(i) = d(i) - y(i). \quad (2.3)$$

O LMS atualiza os coeficientes por

$$\hat{w}(i+1) = \hat{w}(i) + \mu u(i)e(i). \quad (2.4)$$

A curva de aprendizado é estimada pela média sobre as $R = 100$ realizações:

$$\widehat{\text{MSE}}(i) = \frac{1}{R} \sum_{r=1}^R e_r^2(i). \quad (2.5)$$

2.3. Determinação da ordem da planta

Para cada comprimento candidato $L = 1, 2, \dots, 40$, foram estimadas a matriz de autocorrelação e a correlação cruzada:

$$\hat{R}_{u,L} = \frac{1}{N_T} \sum_{r,i} u_r(i) u_r^T(i), \quad \hat{r}_{du,L} = \frac{1}{N_T} \sum_{r,i} u_r(i) d_r(i), \quad (2.6)$$

onde N_T é o número total de amostras processadas. A solução de Wiener de cada modelo é

$$\hat{w}_L = \hat{R}_{u,L}^{-1} \hat{r}_{du,L}. \quad (2.7)$$

Em seguida, o MSE de cada solução é calculado por

$$\hat{J}_L = \frac{1}{N_T} \sum_{r,i} [d_r(i) - \hat{w}_L^T u_r(i)]^2. \quad (2.8)$$




Figura 2.1: MSE da solução de Wiener em função da ordem candidata, utilizando o conjunto de entrada branca.

Para ordens inferiores a 30, o modelo não possui graus de liberdade suficientes para representar toda a resposta ao impulso. O erro diminui em etapas à medida que novos coeficientes relevantes são incluídos.

A queda até aproximadamente -30 dB ocorre quando se utiliza $L = 31$. A partir desse ponto, a inclusão de novos coeficientes não reduz o erro, que permanece limitado pelo ruído de medição. Portanto,

$$M = 30 \quad \text{e} \quad L = 31. \quad (2.9)$$

2.4. Curvas de aprendizado do MSE

2.4.1 Entrada branca

Com $\mu = 0,01$, a curva média sobre as 100 realizações é mostrada na Figura 2.2.




Figura 2.2: Curva de aprendizado do LMS para o caso de entrada branca.

A entrada branca proporciona convergência rápida. Após aproximadamente 500 iterações, a curva já se encontra próxima do regime permanente. A média das últimas 3000 amostras é

$$\text{MSE}_{\infty, \text{branca}} \approx 1,186 \times 10^{-3} \Rightarrow -29,26 \text{ dB}. \quad (2.10)$$

A solução Wiener é $9,9995 \times 10^{-4}$, praticamente -30 dB . A diferença decorre do desajuste do LMS com passo constante.

2.4.2 Entrada correlacionada

Para a entrada correlacionada, adotou-se $\mu = 0,003$. A curva é apresentada na Figura 2.3.




Figura 2.3: Curva de aprendizado do LMS para o caso de entrada correlacionada.

A convergência é consideravelmente mais lenta: a curva se aproxima do regime permanente somente após cerca de 15000 iterações. A média das últimas 5000 amostras é

$$\text{MSE}_{\infty, \text{corr}} \approx 1,053 \times 10^{-3} \Rightarrow -29,77 \text{ dB}. \quad (2.11)$$

O MSE final é ligeiramente menor que no caso branco porque o passo empregado também é menor. Isso não significa que a entrada correlacionada seja mais favorável: ela exige um número muito maior de iterações para atingir o mesmo piso de erro.

Tabela 2.2: Comparação das curvas de aprendizado.

Entrada	Passo μ	Aproximação do regime	MSE em regime
Branca	0,01	cerca de 600 iterações	-29,26 dB
Correlacionada	0,003	cerca de 15000 iterações	-29,77 dB

2.5. Vetor estimado da planta desconhecida

Foram consideradas três estimativas: a média dos vetores finais do LMS com entrada branca, a média dos vetores finais com entrada correlacionada e a solução de Wiener consolidada, obtida a partir das estatísticas dos dois conjuntos.

A distância entre as duas estimativas médias do LMS é

$$\|\hat{w}_{\text{branca}} - \hat{w}_{\text{corr}}\|_2 \approx 1,61 \times 10^{-3}, \quad (2.12)$$

confirmando que os dois conjuntos descrevem a mesma planta. A estimativa consolidada é apresentada na Tabela 2.3.

Tabela 2.3: Coeficientes estimados da planta FIR de ordem 30.

k	$\hat{w}_{\text{white}}(k)$	$\hat{w}_{\text{corr}}(k)$
0	0.4782	0.4783
1	0.1346	0.1364
2	0.2254	0.2259
3	-0.1736	-0.1738
4	-0.0779	-0.0778
5	-0.0448	-0.0444
6	0.1818	0.1811
7	-0.0454	-0.0457
8	0.1150	0.1150
9	-0.3387	-0.3359
10	-0.0570	-0.0580
11	-0.1346	-0.1356
12	-0.2583	-0.2596
13	0.0854	0.0826
14	0.0463	0.0469
15	0.0059	0.0053
16	-0.2199	-0.2177
17	0.1838	0.1852
18	0.0574	0.0581
19	-0.0513	-0.0504
20	0.0047	0.0044
21	-0.0431	-0.0430
22	-0.2886	-0.2867
23	-0.0460	-0.0451
24	-0.1344	-0.1359
25	-0.1580	-0.1603
26	-0.1890	-0.1894
27	-0.0856	-0.0879
28	-0.3296	-0.3287
29	0.1571	0.1570
30	0.0857	0.0850

2.6. Conclusão

O LMS identificou satisfatoriamente as plantas FIR utilizando apenas os pares de entrada e saída. Na primeira parte, as curvas apresentaram redução consistente do erro e valores finais compatíveis com a variância do ruído e com o erro previsto para o passo adotado.

Na segunda parte, a análise permitiu identificar uma planta FIR de ordem

$$M = 30, \quad L = 31. \quad (2.13)$$

Essa ordem foi determinada pela queda do MSE da solução de Wiener até o piso de aproximadamente -30 dB. As curvas de aprendizado também confirmaram a influência das estatísticas da entrada: o sinal branco proporcionou convergência rápida, enquanto a entrada correlacionada exigiu um passo menor e aproximadamente uma ordem de grandeza a mais de iterações.

Por fim, as estimativas obtidas com os dois conjuntos de entrada apresentaram forte concordância, permitindo determinar de maneira confiável os 31 coeficientes da planta. Dessa forma, o experimento demonstrou a convergência do LMS e possibilitou a análise quantitativa do MSE e do EMSE.